Gestion de Projet & Vision par Ordinateur :

Reconstruction Panoramique



<u>Durand Aurélien - M2-SIS</u> <u>Ladjouzi Rachid - M2-SIS</u> Chadee Nopharut - M2-SIS

- I. <u>Détection des points d'intérêts dans une image</u>
- II. Appariement
- III. Homographie

Détecteur de Harris

Origines : Détecteur de Moravec

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

$$G_{y} = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \qquad I_{x} = \frac{\partial}{\partial x} g(x, y)$$
$$I_{y} = \frac{\partial}{\partial y} g(x, y)$$

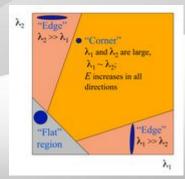
Étapes de l'algorithme

- Calcul des gradients à l'aide d'un filtre (Filtre Gaussien ou Filtre de Sobel).
- Calcul d'un tenseur de structure à l'aide d'un filtre Gaussien.
- A partir du tenseur de structure, calcul des valeurs propres de la fonction de réponse ; ce sont les directions principales des gradients locaux de l'image.
- 4. Seuillage et suppression non-maximale des valeurs de R.

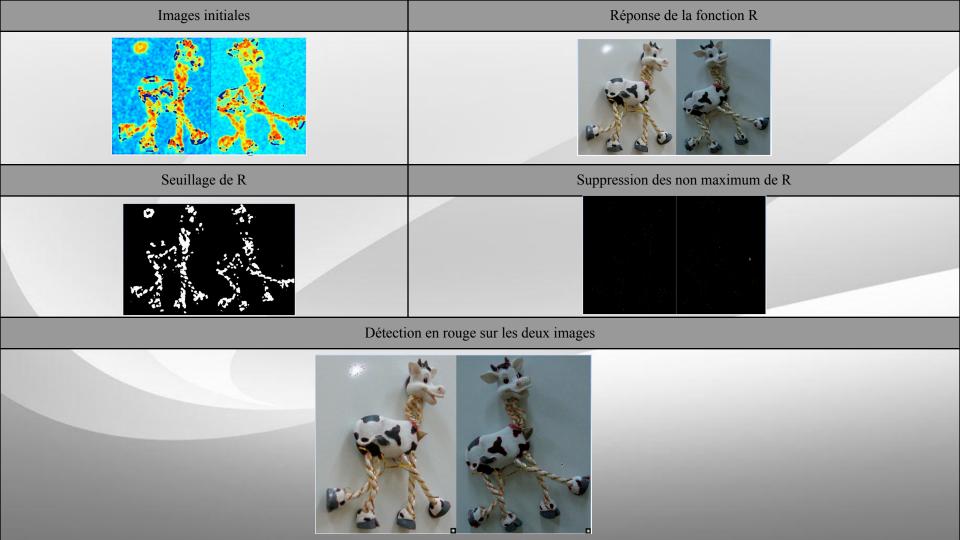
Avantages/Inconvénients

- ✓ Invariance par rotation et translation.
- ✓ Invariance par changement d'intensité lumineuse.
- X Peu robuste au changement d'échelle (l'algorithme SIFT permet de corriger cet inconvénient).

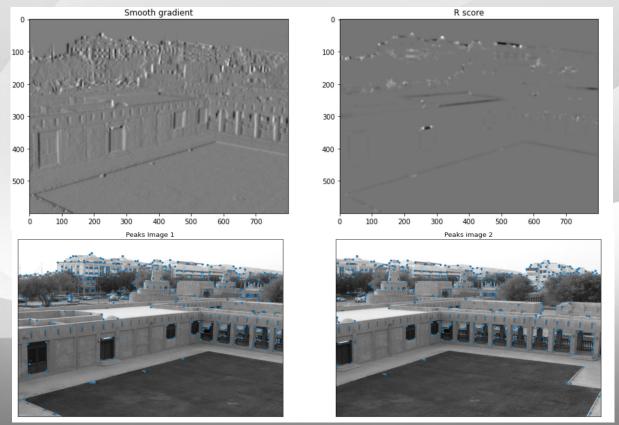
$$M = g(x,y) * \begin{bmatrix} \sum I_x^2 & \sum I_x I_y \\ \sum I_x I_y & \sum I_y^2 \end{bmatrix}$$



$$R = det(M) - \alpha \cdot trace(M)^2$$



a) <u>Détecteur de Harris</u>

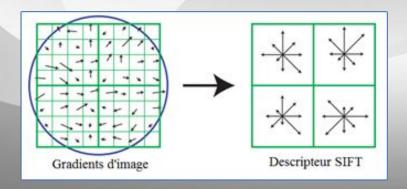


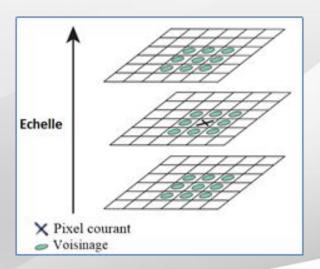
b) <u>Détecteur Sift</u>

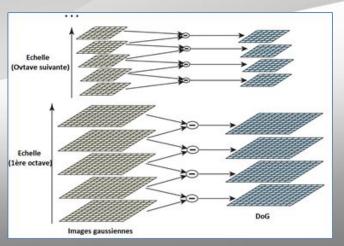
- Inspiré du détecteur de Harris.
- contourne les limites de Harris.
- Descripteurs invariants à la rotation, au changement d'échelle et partiellement à la luminosité.

Algorithme:

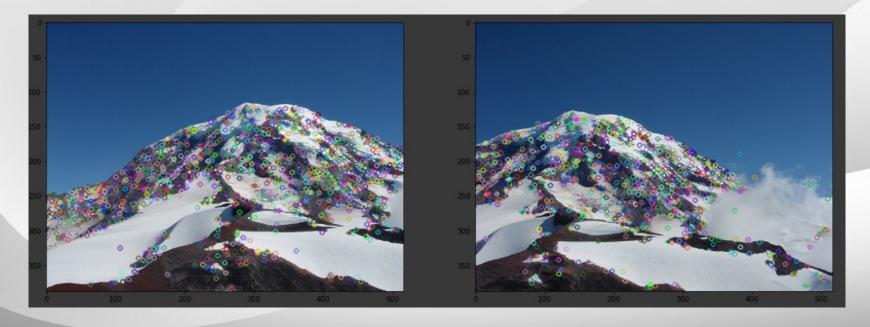
- Construction de l'espace des échelles avec 4 octaves différentes.
- Détection des extremums locaux dans un voisinage de 26 pixels.
- Localisation des points d'intérêt.
- Affectation d'orientations aux points d'intérêt.
- Calcul des descripteurs.





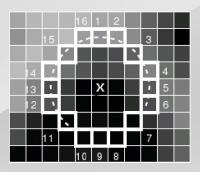


b) <u>Détecteur Sift</u>



c) <u>Détecteur</u> Fast

- Rapide
- Pas de descripteur
- Invariant aux changement d'intensité
- Non invariant aux changement d'échelle



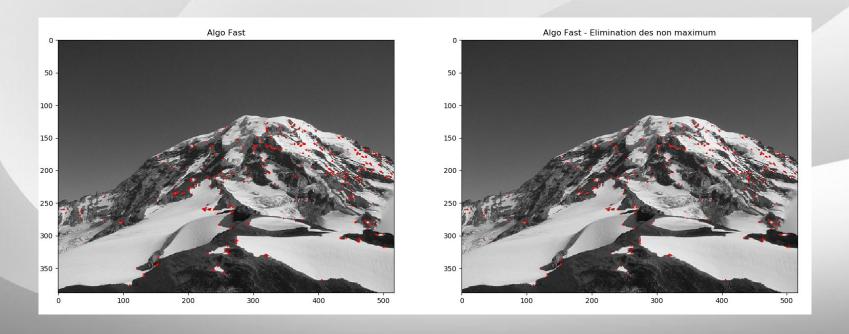
$$S_{p \to x} = \begin{cases} d, & I_{p \to x} \leq I_p - t \\ s, & I_p - t < I_{p \to x} < I_p + t \\ b, & I_p + t \leq I_{p \to x} \end{cases}$$

Algo:

- Etablissement du patch autour du pixel considéré
- Vérification sur les pixel 1-9 que p1 et p9 ne soit pas dans le seuil t respectivement pour 5-13
- Vérification que n point du patch soit de catégorie d ou b (n = 9 meilleur valeur de détection)
- Élimination des non maximums avec la fonction de score V

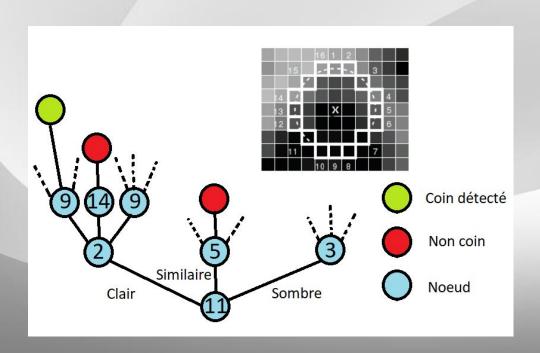
$$V = \max \begin{cases} \sum (\text{pixel values} - p) \text{ if } (\text{value} - p) > t \\ \sum (p - \text{pixel values}) \text{ if } (p - \text{value}) > t \end{cases}$$

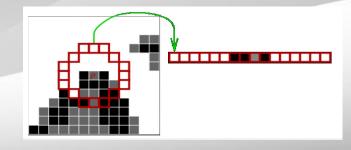
c) <u>Détecteur</u> Fast



- I. <u>Détection des points d'intérêt dans une image :</u>
- c) <u>Détecteur</u> Fast

Detecteur Fast et deep learning



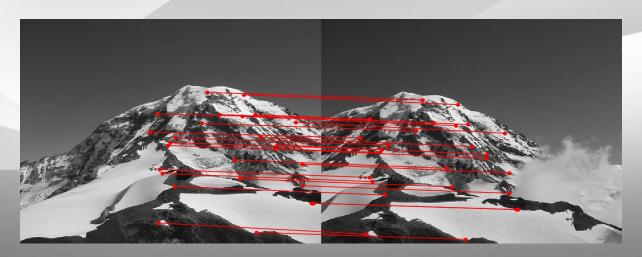


II. Appariement - Fast

A partir d'une détection de points d'intérêt on souhaite maintenant apparié les correspondances.

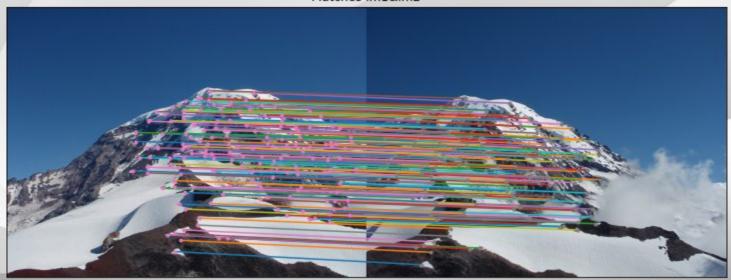
Plusieurs méthodes possible, dont la somme des écarts à la moyenne :

$$ZMSSD(c_1, c_2) = \sum_{p_1 \in R_1, p_2 \in R_2, p_1 \leftrightarrow p_2} \left[(I_1(p_1) - \mu_1) - (I_2(p_2) - \mu_2) \right]^2$$



II. Appariement - Harris

Matches im1&im2



II. Appariement - Sift



a) Principe de l'Homographie

Équation du type:
$$x = Hy$$

Qui revient à calculer:
$$\begin{bmatrix} wx_1 \\ wy_1 \\ w \end{bmatrix} = \begin{bmatrix} h_{00} & h_{01} & h_{02} \\ h_{10} & h_{11} & h_{12} \\ h_{20} & h_{21} & h_{22} \end{bmatrix} \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix}$$

Il faut alors résoudre le système suivant pour n=4:

$$\begin{bmatrix} x_{2,1} & y_{2,1} & 1 & 0 & 0 & 0 & -x_{1,1} x_{2,1} & -x_{1,1} y_{2,1} \\ 0 & 0 & 0 & x_{2,1} & y_{2,1} & 1 & -y_{1,1} x_{2,1} & -y_{1,1} x_{2,1} \\ \vdots & \vdots \\ x_{2,n} & y_{2,n} & 1 & 0 & 0 & 0 & -x_{1,n} x_{2,n} & -x_{1,n} y_{2,n} \\ 0 & 0 & 0 & x_{2,n} & y_{2,n} & 1 & -y_{1,n} x_{2,n} & -y_{1,n} x_{2,n} \end{bmatrix} \begin{bmatrix} h_{00} \\ h_{01} \\ h_{02} \\ h_{10} \\ h_{11} \\ \vdots \\ x_{1,n} \\ y_{1,1} \end{bmatrix}$$

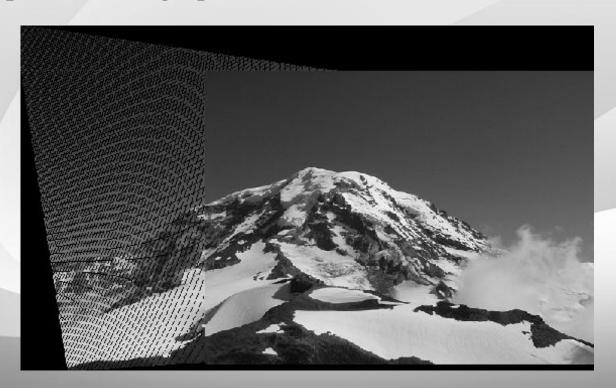
a) Principe de l'Homographie

Méthode des moindres carrés: Ah = b

- Décomposition en valeur singulière de A c'est à dire la diagonaliser telle que $A = UDV^T$, la matrice des vecteurs à gauche, V la matrice des vecteurs à droite et D la Diagonale contenant les valeurs propres de A.
- On calcule ensuite $b' = U^T b$
- Calculer $y_i = b_i'/d_i$
- La solution pour h est alors h = Vy

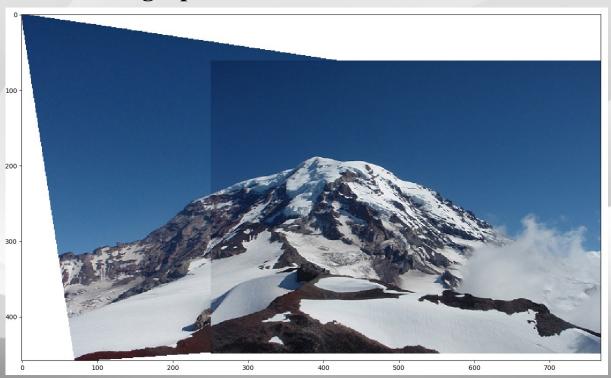
Transformation Backward:

a) Principe de l'Homographie



Homographie direct

a) Principe de l'Homographie



Homographie et Transformation Backward

b) Stratégie de Ransac (Random Sample Consensus)

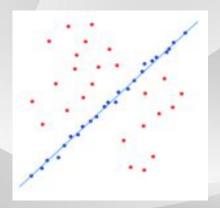
- Permet de déterminer les paramètres d'un modèle qui se rapproche au maximum de tous les « inliers ».
- Utilise le schéma de vote pour trouver le résultat d'ajustement optimal
- Les données d'entrée :
 - N : le nombre minimum de données nécessaires pour ajuster le modèle.
- K : le nombre maximal d'itérations de l'algorithme.
- T : une valeur seuil pour déterminer si une donnée correspond à un modèle ou pas.
- D : le nombre de données proches des valeurs nécessaires pour faire valoir que le modèle correspond bien aux données.
- Les sorties :
- Meilleur modèle
- Points du meilleur ensemble
- Erreur du meilleur modèle

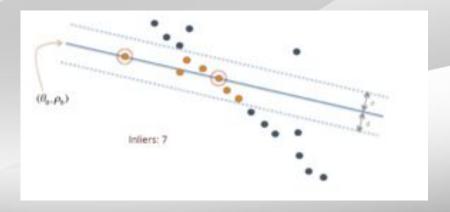
b) <u>Stratégie de Ransac (Random Sample Consensus)</u>

- Sélectionner au hasard un échantillon de sous-ensemble contenant un minimum d'éléments de données dans l'ensemble de données d'entrée.
- Calculer un modèle d'ajustement et les paramètres de modèle correspondants en utilisant uniquement les éléments de cet échantillon de sous-ensemble.
- Vérifier quels éléments de l'ensemble de données sont cohérents avec le modèle instancié par les paramètres estimés du modèle obtenus à partir de la première étape.
- Un élément de données sera considéré comme une valeur aberrante s'il ne correspond pas au modèle d'ajustement instancié par l'ensemble des paramètres estimés du modèle dans un certain seuil d'erreur.
- Répéter de manière itérative les étapes ci-dessus jusqu'à ce que le consensus obtenu défini dans une certaine itération ait suffisamment d'inliers.

b) Stratégie de Ransac (Random Sample Consensus)

- Utiliser pour mesurer les translations et rotations des différents pixels afin de pouvoir créer l'image panoramique.
- Afin d'obtenir 4 appariement correct pour calculer la matrice d'homographie il faut utiliser une stratégie de type Ransac sur la liste d'appariement obtenue aux étapes d'avant.





III. <u>Homographie</u>

c) Homographie et deep learning

- Estimation d'homographie à l'aide du Deep Learning.
- Requiert une quantité de données **considérable**.

Étapes de l'algorithme (pour chaque image)

- 1. Rogner l'image pour en extraire un patch carré.
- 2. "Perturber" les 4 coins du patch : une homographie est ainsi définie à partir de cette perturbation.
- 3. Appliquer l'inverse de l'homographie à l'image.
- 4. À partir de l'image résultante, créer un patch carré dans les mêmes conditions que (1).
- 5. Les 2 patchs créés sont envoyés au réseau de neurones. On peut, à partir de ces patchs, estimer une paramétrisation à 4 points d'une homographie.



Conclusion